

Aplicações Limitadas por Memória e por CPU

Eugênio Vitor Lopes dos Santos

DCA3703 – Programação Paralela, Universidade Federal do Rio Grande do Norte

1 Enunciado

Implemente dois programas paralelos em C com OpenMP: um limitado por memória, com somas simples em vetores, e outro limitado por CPU, com cálculos matemáticos intensivos. Paralelize com `#pragma omp parallel for` e meça o tempo de execução variando o número de threads. Analise quando o desempenho melhora, estabiliza ou piora. Reflita sobre como o multithreading de hardware pode ajudar programas memory-bound e atrapalhar programas compute-bound pela competição por recursos.

2 Fundamentação

Uma aplicação memory-bound transfere muitos dados e realiza poucas operações por byte. Cada iteração lê dois valores e escreve um valor. O gargalo é a largura de banda da memória. A soma faz uma operação de ponto flutuante para cada 24 bytes transferidos, sem contar efeitos de cache.

Uma aplicação compute-bound realiza muitas operações antes de acessar novos dados. Aqui, cada elemento roda 50 repetições de `sqrt` e `sin`. O cálculo dessas funções leva mais tempo que ler e escrever um único elemento. Sem conhecer a implementação da biblioteca matemática, não dá para atribuir um número exato de FLOPs. A classificação depende do comportamento do laço, não de uma estimativa precisa de FLOPs.

O multithreading de hardware ajuda uma aplicação memory-bound porque, enquanto uma thread espera dados da memória, outra pode executar. O ganho depende da latência e da largura de banda disponíveis. Quando a largura de banda satura, threads adicionais competem pelo mesmo recurso. Em uma aplicação compute-bound, threads lógicas do mesmo núcleo físico compartilham unidades de execução, caches e outros recursos. O paralelismo pode não reduzir o tempo ou até aumentá-lo por causa dessa competição.

3 Implementação

O enunciado pede “dois programas”, mas esta implementação usa um único arquivo e um único executável com dois testes independentes, medidos separadamente. Isso evita repetir código de alocação, inicialização, medição e configuração de threads. Os dois casos exigidos ficam preservados: o primeiro laço é memory-bound e o segundo é compute-bound.

O teste memory-bound aloca os vetores A, B e C e calcula $C[i] = A[i] + B[i]$. Cada thread escreve em uma posição diferente de C. O teste compute-bound aplica 50 repetições de `sqrt` e `sin` a cada elemento de V. A variável temporária `val` é privada de cada iteração. Alocação e preenchimento dos vetores acontecem antes dos cronômetros. Cada medição cobre somente o seu laço paralelo.

```

1  #define _POSIX_C_SOURCE 199309L
2
3  #include <stdio.h>
4  #include <stdlib.h>
5  #include <time.h>
6  #include <math.h>
7  #include <omp.h>
8
9  #define TOTAL_ELEMENTOS_PADRAO 50000000L
10
11 static double obter_tempo_segundos(void) {
12     struct timespec tempo_atual;
13     clock_gettime(CLOCK_MONOTONIC, &tempo_atual);
14     return (double)tempo_atual.tv_sec + (double)tempo_atual.tv_nsec / 1e9;
15 }
16
17 int main(int argc, char **argv) {
18     long total_elementos = argc > 1 ? atol(argv[1]) :
19         TOTAL_ELEMENTOS_PADRAO;
20     if (total_elementos <= 0) {
21         fprintf(stderr, "Uso: %s [total_elementos]\n", argv[0]);
22         return 1;
23     }
24
25     double *A = malloc((size_t)total_elementos * sizeof(*A));
26     double *B = malloc((size_t)total_elementos * sizeof(*B));
27     double *C = malloc((size_t)total_elementos * sizeof(*C));
28     double *V = malloc((size_t)total_elementos * sizeof(*V));
29
30     if (!A || !B || !C || !V) {
31         perror("malloc");
32         return 1;
33     }
34
35     for (long i = 0; i < total_elementos; ++i) {
36         A[i] = (double)i * 0.5;
37         B[i] = (double)i * 0.25;
38         V[i] = (double)i * 0.1;
39     }
40
41     int total_threads = omp_get_max_threads();
42
43     double tempo_inicio_memoria = obter_tempo_segundos();
44
45     #pragma omp parallel for
46     for (long i = 0; i < total_elementos; ++i) {
47         C[i] = A[i] + B[i];
48     }

```

```

48
49     double tempo_execucao_memoria = obter_tempo_segundos() -
        tempo_inicio_memoria;
50
51     double tempo_inicio_cpu = obter_tempo_segundos();
52
53     #pragma omp parallel for
54     for (long i = 0; i < total_elementos; ++i) {
55         double val = V[i];
56         for (int j = 0; j < 50; ++j) {
57             val = sqrt(val + j * 0.01) + sin(val);
58         }
59         V[i] = val;
60     }
61
62     double tempo_execucao_cpu = obter_tempo_segundos() - tempo_inicio_cpu;
63
64     printf("N=%ld threads=%d memory_bound=%.9f cpu_bound=%.9f\n",
65           total_elementos, total_threads, tempo_execucao_memoria,
66           tempo_execucao_cpu);
67
68     free(A); free(B); free(C); free(V);
69
70     return 0;
71 }

```

Listing 1: Testes limitado pela memória e limitado pela CPU

O arquivo é compilado com GCC, `-fopenmp` e `-lm`. O programa recebe o número de elementos como argumento e usa $N = 50.000.000$ como padrão. Os testes deste relatório usam $N = 5.000.000$. A medição usa `CLOCK_MONOTONIC`, que não é afetado por alterações no relógio do sistema.

```

1 gcc -std=c11 -Wall -Wextra -fopenmp tarefa04.c -o tarefa04 -lm
2
3 OMP_NUM_THREADS=1 ./tarefa04 5000000
4 OMP_NUM_THREADS=28 ./tarefa04 5000000

```

Listing 2: Compilação e execução dos testes

4 Resultados e Discussão




Figure 1: Tempo de execução em função do número de threads.

O programa memory-bound melhora quando o número de threads aumenta no início. Depois, o tempo apresenta pouca redução e oscila. Em alguns pontos, o tempo sobe. Esse comportamento aponta saturação ou disputa pela largura de banda da memória.

O programa compute-bound também melhora com mais threads enquanto existem recursos de CPU disponíveis. Depois disso, o ganho diminui e pode desaparecer. Se threads lógicas compartilham o mesmo núcleo físico, a competição por unidades de cálculo pode causar estabilidade ou piora.

Intensidade: $\sim 1050/16 \approx 65,6$ FLOP/byte. Bem à direita do ponto de crista ($\sim 6,4$), onde a CPU define o limite. Com 20 threads sobe a ~ 120 GFLOP/s. Fica longe dos 350 GFLOP/s teóricos porque não usa vetorização AVX2/FMA e `sqrt/sin` rodam em software escalar.

`sqrt` e `sin` não são 1 FLOP cada. São funções de biblioteca com dezenas de operações internas: Newton-Raphson, polinômios minimax. A estimativa de ~ 1050 FLOPs é razoável para o custo real em software.

5 Conclusão

Os dois testes paralelos usam OpenMP e permitem comparar dois tipos de gargalo. Em uma aplicação memory-bound, o multithreading de hardware ajuda porque, enquanto uma thread aguarda dados da memória, outra pode executar. O ganho existe enquanto a largura de banda da memória não está saturada. Quando múltiplos núcleos lógicos compartilham o mesmo barramento de memória, threads adicionais competem pelo mesmo recurso e os ganhos se estabilizam ou diminuem. Em uma aplicação compute-bound, threads lógicas do mesmo núcleo físico compartilham unidades de execução e caches. O paralelismo pode não reduzir o tempo e até aumentá-lo: mais threads significam mais competição pelos mesmos recursos de cálculo, sem o benefício de esconder latência de memória.